

Embedded Object Detection su ESP32-S3: ottimizzazione e deployment per l'Edge

Dipartimento di Informatica - Scienza e Ingegneria

Corso di Laurea in Informatica

**Relatore: Luciano Bononi
Co-Relatore: Giorgio Tsiotas**

**Presentata da: Alessio Prato
Data: 31 Ottobre 2025**

Edge AI e TinyML


VANTAGGI DI QUESTI PARADIGMI

- **Hardware a basso costo**
- **Indipendenza dalla rete e minor latenza**
- **Privacy**
- **Efficienza Energetica**

Hardware e Modello scelti


ESP32-S3 CUSTOM BOARD

- Dual-core Xtensa LX7 240 Mhz SIMD
- 512 KB SRAM
- 8 MB PSRAM
- Camera integrata OV3660



YOLOv11

- Real-time Object Detection
- Pre-trained su COCO dataset



Sviluppo Firmware e Interfacce di Test

- C++ con FreeRTOS
- Tasks separati per la concorrenza
- Mutex per mutua esclusione su frame buffer Camera
- Message Queue per disaccoppiamento acquisizione frame buffer da elaborazione inferenza

CLI

```
ESP32CAM_ESPIDF — Python • idf.py -p /dev/cu.usbmodem101 monitor — 102x34
=====
INTERFACCIA A RIGA DI COMANDO
=====
w: Avvia il webserver per web UI
+: aumenta risoluzione fotocamera
-: riduci risoluzione fotocamera
h: mostra i comandi disponibili
l: accendi il LED
k: spegni il LED
=====
COMANDI DI INIZIALIZZAZIONE
=====
i: Inizializza la fotocamera e istanzia i modelli Face Detection e YOLO
d: Deinizializza la fotocamera e i modelli Face Detection e YOLO
=====
COMANDI DI INFERENZA
=====
s: Scatta foto ed esegui inferenza Yolo
a: Scatta foto ed esegui inferenza Face Detection
=====
COMANDI DI MONITORAGGIO
=====
p: Avvia monitoraggio continuo
q: Ferma monitoraggio continuo
b: Benchmark performance
l: Mostra informazioni Flash
v: Mostra informazioni partizioni
z: Mostra riepilogo storage
m: Mostra statistiche di monitoraggio
t: Mostra statistiche task
r: Mostra statistiche RAM
=====
e: Esci
Inserisci un comando:
```

GUI




Deployment e Problemi


- **Scelto YOLOv11n pre-addestrato sul dataset COCO**
- **Esportazione ONNX per migliorare efficienza inferenza**
- **Quantizzazione PTQ da FLOAT32 a INT8**

Tabella 4.3: Tempi di inferenza di YOLOv11n INT8 (Pre-trained COCO) su ESP32-S3 al variare dell'immagine size

Image Size	Pixel	Tempo (ms)
64×64	4,096	480 ± 2
96×96	9,216	1126 ± 3
128×128	16,384	2068 ± 4
160×160	25,600	3307 ± 3
320×320	102,400	14043 ± 11
640×640	409,600	59240 ± 34



(a) True Positive



(b) False Negative

Model Scaling

OBIETTIVO: ridurre la dimensione del modello

- Dimezzata la larghezza (width) del modello
- Ridotta complessità Detection Head da 80 classi a 1 sola classe (person)
- Denotato come “YOLOv11micro”

Tabella 4.4: Confronto di dimensione dei modelli


Modello	Size(MB)	Parametri	GFLOPs	Classi
YOLOv11n	5,6	2,624,080	6,5	80
YOLOv11micro	2	864,600	2,7	80
YOLOv11micro	1,9	816,219	2,4	1

Tabella 4.5: Tempi di inferenza di YOLOv11micro INT8 (con pesi random) su ESP32-S3 al variare dell'*image size*

Image Size	Pixel	Tempo (ms)
64 × 64	4,096	123 ± 2
96 × 96	9,216	274 ± 3
128 × 128	16,384	500 ± 4
160 × 160	25,600	813 ± 3
320 × 320	102,400	3545 ± 10
640 × 640	409,600	15686 ± 24

Metriche quantitative di accuratezza

$$\text{IoU} = \frac{\text{Area}(B_{pred} \cap B_{gt})}{\text{Area}(B_{pred} \cup B_{gt})}$$



$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

$$\text{AP@50} = \int_0^1 P(R) dR \quad \text{con } \text{IoU}_{\text{th}} = 0.5$$


STEP 1

Warm-up


OBIETTIVO: apprendere feature di alto livello e stabilizzare training successivi

Tabella 4.6: Argomenti di *training*, *warm-up*

Iperparametro	Valore
freeze	0
batch	16
epochs	30
imgsz	640
close mosaic	15
mosaic	0.5
amp	True
lr0	0.01



(a) AP@50



(b) AP@[50:95]

Figura 4.10: Avanzamento dell' AP durante il training





Figura 4.11: Confronto *Average Precision* classe person tra YOLOv11n e YOLOv11micro, su val2017 COCO

STEP 2

Resolution Adaptation


OBIETTIVO: migliorare l'accuratezza del modello sulle quattro image size che garantiscono un tempo di inferenza inferiore ad 1 secondo

Iperparametro	Valore
freeze	0
batch	64
epochs	200
imgsz	x
close mosaic	180
mosaic	0.7
amp	False
lr0	0.01



(a) Image size 64

(b) Image size 96



(c) Image size 128

(d) Image size 160

Figura 4.13: Confronto dell'*Average Precision* sulla classe *person* tra YOLOv11n_y e YOLOv11micro_RA_y su COCO val2017.



(a) YOLOv11n_96

(b) YOLOv11micro_RA_96

Figura 4.14: Esempio di confronto inferenza, YOLOv11micro dopo resolution adaptation su imgsz x piccola, rileva persone meglio di YOLOv11n esportato con medesima imgsz, immagine da COCO val2017


STEP 3

Domain Adaptation


OBIETTIVO: migliorare l'accuratezza del modello sul dominio finale, utilizzando un dataset di 1300 immagini acquisite con la camera della scheda, tramite **progressive unfreezing**

Tabella 4.8: Argomenti di *training*, *domain adaptation*

Head		Full	
Iperparametro	Valore	Iperparametro	Valore
freeze	23	freeze	0
batch	64	batch	64
epochs	50	epochs	100
imgsz	x	imgsz	x
close mosaic	30	close mosaic	60
mosaic	0.5	mosaic	0.5
amp	False	amp	False
lr0	0.005	lr0	0.001




(a) Image size 64 (b) Image size 96



(c) Image size 128 (d) Image size 160

Figura 4.16: Confronto dell'*Average Precision* sulla classe *person* di YOLOv11micro dopo *domain adaptation*, su *esp-person test set*.



(a) YOLOv11micro_RA_96 (b) YOLOv11micro_DA_96

Figura 4.17: Esempio di confronto inferenza *on deploy*

Conclusioni

- I layer convoluzionali con alto errore di quantizzazione layer-wise vengono mantenuti in INT16 per diminuire l'errore complessivo

Tabella 4.9: Tempi di inferenza di YOLOv11micro INT8 con nuovi argomenti di quantizzazione, su ESP32-S3 al variare dell'*image size*

Image Size	Pixel	Tempo (ms)
64×64	4,096	128 ± 2
96×96	9,216	289 ± 4
128×128	16,384	546 ± 3
160×160	25,600	873 ± 10



Figura 4.18: *Person detection* su ESP32-S3 con i quattro modelli ottenuti. Dall'alto a sinistra procedendo in senso antiorario: YOLOv11micro_DA_64/96/128/160

Grazie per l'attenzione